

빅데이터분석프로그래밍 기말
프로젝트

YouTube

바이럴 예측 서비스

업로드 전 메타데이터
입력



AI가 바이럴 가능성 & 예상 조회수 범위 예측

박채원 | 20241487

문제정의 & 데이터

풀려는 문제

"업로드 전에 이 영상이 바이럴될까?"

카테고리·태그·요일·시각 등
사전 정보만으로 바이럴 여부를
예측하고 최적 업로드 전략을
제안한다.



데이터셋

161,470

행 (영상 수)

18

원본
컬럼

4개국

US · GB · CA ·
FR


출처 : Kaggle — YouTube Trending Videos Dataset

형식 : CSV | 라이선스 : 공개 데이터 (Kaggle)


타겟 변수 : is_viral (조회수 75th pct ≈ 133만 뷰 초과)

EDA 핵심 발견

카테고리별 평균 조회수



카테고리별 바이럴 비율 (%)



→ Music 바이럴 53.3% — 압도적 1위 — 카테고리 선택만으로 바이럴 확률이 2배 이상 달라진다

시간대별 바이럴 비율



→ 금요일 새벽 4~5시(UTC) 업로드 = 바이럴 비율 최고점 (0.63) — 업로드 타이밍이 콘텐츠만큼 중요하다



라이브 데모

① 입력화면

4. 바이럴 가능성 예측해 보기

업로드 전 영상 메타데이터를 입력하면 AI가 바이럴 가능성과 예상 조회수 범위를 분석합니다.

카테고리

17 — Sports

예상 좋아요 비율

0.95

태그 수

33

업로드 요일

금요일(추천)

제목 길이 (글자 수)

40

☒ 댓글 비활성화

☒ 좋아요 비활성화

업로드 예정 시각 (UTC hour)

20

바이럴 가능성 예측

③ AI 분석 피드백

AI 분석 피드백

바이럴 확률 1.1% — 현재 설정으로는 바이럴이 어렵습니다. 전략 수정이 필요합니다.

잘 된 점

- ✅ 업로드 요일: Friday은 바이럴 비율 29.6%로 좋은 타이밍입니다.
- ✅ 태그 수: 33개로 바이럴 영상 평균(19개) 이상입니다.
- ✅ 제목 길이: 40자로 바이럴 평균(47자)에 근접합니다.

개선이 필요한 점

- ⚠️ 카테고리: Sports은 바이럴 비율 17.3%로 불리합니다. 카테고리 변경을 고려해보세요.
- ⚠️ 댓글/좋아요: 비활성화 시 알고리즘 engagement 신호가 줄어 바이럴에 불리합니다.

② 예측 결과



바이럴 확률

1.1%

예상 조회수 범위

6만 ~ 51...



④ 참고 사항

참고 사항

➡ 업로드 시각: UTC 20시 — UTC 4~5시 대비 바이럴 효과가 다소 낮을 수 있습니다.

모델 · 특성 · 성능

새로 만든

피처

`like_ratio` 좋아요 / (좋아요+싫어요) — 채널 규모 무관

`tag_count` 태그 개수 — 바이럴 평균 19개
`title_len` 제목 글자 수 — 짧을수록 소폭 유리

`days_to_trending` 트렌딩까지 일수 — 바이럴은 평균 40분
`is_weekend` 주말 여부 — 평일이 바이럴에 유리

`publish_hour` 업로드 시각 — UTC 4~5시 최고

`published_day_of_week` 업로드 요일·시간 — 바이럴 상관 높음

`time_frame` 업로드 시간대 — 시각별 바이럴 패턴 분석에 사용

모델 선택

이유

Logistic Reg.

베이스라인 — 선형 관계

Random Forest

기준점 피처 중요도 해석 가능

XGBoost



불균형 데이터에 강함(scale_pos_weight=3)

모델 성능

비교

모

델

정확

도

F1

ROC-AUC

Logistic Reg.

~75%

~0.72

~0.78

Random Forest

~82%

~0.81

~0.87

XGBoost ★

~83%

~0.82

~0.88

6. 결론 & 한계

알게 된
것

카테고리와 업로드 타이밍이 가장 강력한 바이럴 신호

⚠️ 아쉬운 점

데이터의 규모가 작아서 일부 구간에서 신뢰성이 낮아질 수 있다

📌 향후
과제

구독자 수 데이터를 추가로 확보