

프로젝트

EDA

시각화

모델·서비스

YouTube 바이럴 예측

빅데이터분석프로젝트 기말 프로젝트

박채원 / 20241487

시각화 – 그래프로 인사이트 찾기


그래프 1 – 분포

볼 컬럼

log_views

☒ 바이럴 여부
로 색 구분

log_views 분포



📌 **해석:** log_views 기준 바이럴(빨강) 중앙값은 약 15.0, 비바이럴(파랑)은 약 12.3으로 두 분포가 오른쪽으로 뚜렷이 분리됩니다. 조회수 자체가 바이럴 예측의 가장 강력한 신호이지만, 업로드 전 예측에는 사용할 수 없으므로 제목·태그·시간 등 사전 피처에 집중해야 합니다.

그래프 2 – 관계

X축

log_views


Y축

like_ratio

샘플 수 (속도)

5000


log_views vs like_ratio



◆ **해석:** log_views가 높을수록 like_ratio도 대체로 높으며, 바이럴 영상이 우상단에 집중됩니다. 단, like_ratio 상위 25% 영상의 바이럴 비율은 20.1%로 전체 평균(25.0%)보다 오히려 낮습니다. 좋아요 비율이 높다고 무조건 바이럴로 이어지지 않으며, 절대적인 조회수·좋아요 수가 더 중요한 신호입니다.

그래프 3 — 카테고리별 조회수 분포

카테고리별 log(views) 분포 — 바이럴 여부 비교




log(1+views)

🔴 **해석:** Music 카테고리는 바이럴 IQR이 비바이럴보다 현저히 오른쪽에 위치하며, 바이럴 비율 53.3%로 전 카테고리 중 압도적 1위입니다. 반면 News & Politics는 바이럴/비바이럴 간 IQR 겹침이 크고 바이럴 비율 6.8%로 최하위 — 단기 소비성 뉴스 콘텐츠의 특성을 반영합니다. 카테고리 피처가 모델에 유효한 이유를 시각적으로 확인할 수 있습니다.

그래프 4 — 업로드 시간대 × 요일 바이럴 비율

요일 × 업로드 시각별 바이럴 비율




🔴 **해석:** 금요일 새벽 4시(UTC) 조합이 바이럴 비율 63.3%로 전체 최고점입니다. 금요일·목요일 새벽 4시(UTC)가 집중적으로 높는데, 이는 미국 영국 기준 전날 저녁 업로드와 일치합니다. 반면 토요일 오전 9~10시(UTC)는 1.1~1.2%로 최저 — 주말 낮 시간대는 경쟁이 물리고 알고리즘 노출이 분산됩니다.

그래프 5 — 태그 수 & 제목 길이와 바이럴의 관계

바이럴 여부별 태그 수

바이럴 여부별 제목 길이



◆ **해석:** 바이럴 영상의 태그 수 중앙값은 19개, 비바이럴은 15개로 약 4개 차이가 납니다. 차이가 크지는 않지만 태그를 충분히 채우는 습관이 바이럴에 소폭 유리하게 작용합니다.

◆ **해석:** 제목 길이 중앙값이 바이럴 47자, 비바이럴 51자로 오히려 바이럴이 약간 짧습니다. IQR 범위도 거의 겹쳐 단독 피쳐로서의 예측력은 낮습니다. 제목 길이 보다는 키워드·감정 표현 등 내용이 더 중요한 신호입니다.