

프로젝트

EDA

시각화

모델·서비스

YouTube 바이럴 예측

빅데이터분석프로젝트 기말 프로젝트

박채원 / 20241487

EDA — 데이터 살펴보기

1. 데이터 개요

행 수	열 수	결측 있는 열	바이럴 비율
161,...	25	1	25.0%

미리보기 (상위 20행)

	index	video_id	trending_date	title
0	0	2kyS6SvSYSE	2017-11-14 00:00:00	WE WANT TO TALK ABOUT YOU
1	1	1ZAPwfrtAFY	2017-11-14 00:00:00	The Trump Presidency: Lessons Learned
2	2	5qpjK5DgCt4	2017-11-14 00:00:00	Racist Superman Rudy M
3	3	puqaWrEC7tY	2017-11-14 00:00:00	Nickelback Lyrics: Real or Imagi
4	4	d380meD0W0M	2017-11-14 00:00:00	I Dare You: GOING BALD!?
5	5	gHZ1Qz0KiKM	2017-11-14 00:00:00	2 Weeks with iPhone X
6	6	39idVpFF7NQ	2017-11-14 00:00:00	Roy Moore & Jeff Sessions
7	7	nc99ccSXST0	2017-11-14 00:00:00	5 Ice Cream Gadgets put t
8	8	jr9QtXwC9vc	2017-11-14 00:00:00	The Greatest Showman C
9	9	TUmyygCMMGA	2017-11-14 00:00:00	Why the rise of the robots

2. 요약 통계


	count	mean	std	min	25%	50%
views	161470	2419854.1	10437486.87	223	101538.25	384
likes	161470	65661.94	226061.67	0	1975	
dislikes	161470	3490.15	31147.79	0	85	
comment_count	161470	7035.49	34041.21	0	279	
days_to_trending	161470	14.71	145.19	0	1	
like_ratio	160032	0.93	0.1	0	0.92	
tag_count	161470	17.94	12.55	0	8	
title_len	161470	54.39	25.65	1	36	



3. 결측치



4. 타겟 분포

바이럴 레이블 (75th pct 기준) 조회수 분포 (log scale)






5. 카테고리별 분석

카테고리별 평균 조회수




카테고리별 바이럴 비율 (%)





6. 시간 피쳐 분석

요일별 바이럴 비율 (%)




트렌딩까지 걸린 일수 분포





7. 수치 피쳐 상관관계


Pearson Correlation Heatmap



8. 국가별 분포

국가별 영상 수 및 바이럴 비율





9. 내가 발견한 것

데이터 구조

- 총 161,470행, 18개 원본 컬럼 + 파생 컬럼 추가
- 4개국 데이터: US / GB / CANADA / FRANCE (각 약 4만 건으로 균등 분포)
- 바이럴 기준: 조회수 75th percentile $\approx$ 133만 뷰 $\rightarrow$ 바이럴:비바이럴 = 25%:75% (클래스 불균형 존재)

카테고리 인사이트

- Music 카테고리가 바이럴 비율 53.3%로 압도적 1위 — 평균 조회수도 약 822만으로 최고
- Entertainment는 전체 영상의 26%를 차지하는 가장 많은 카테고리이지만, 바이럴 비율은 21.7%로 중간 수준
- News & Politics는 영상 수(11,623개)에 비해 바이럴 비율이 6.8%로 가장 낮음 — 단기 소비성 콘텐츠 특성
- Film & Animation은 적은 영상 수(9,139개)에도 바이럴 비율 33.2% — 예고편·클립의 팬덤 효과

시간 피쳐 인사이트

- 금요일(29.6%)·목요일(28.7%) 업로드가 바이럴 비율 가장 높음 — 주말 시청 급증 효과
- 토요일(18.8%) 이 가장 낮음 — 이미 주말이라 경쟁 영상이 많고 새 영상 소비가 분산됨
- 업로드 시각은 새벽 4~5시(UTC 기준)가 바이럴 비율 최상위 — 실제 현지 저녁 시간대와 일치할 가능성
- 트렌딩까지 걸린 일수: 바이럴 영상 평균 0.03일($\approx$ 40분) vs 비바이럴 0.35일 $\rightarrow$ 바이럴은 업로드 직후 빠르게 반응

상관관계 & 피쳐 인사이트

- **likes**($r=0.41$)가 **is_viral**과 가장 높은 상관관계 — **views**($r=0.35$)보다도 높음
- **views**와 **likes** 간 상관관계가 매우 높아 **다중공선성 주의 필요** (둘 다 모델 입력 시 중복 정보)
- **title_len**($r=-0.09$): 제목이 **짧을수록** 바이럴 확률 소폭 상승 — 바이럴 평균 50자 vs 비바이럴 56자
- **tag_count**: 바이럴 영상이 평균 **19.2개** 태그, 비바이럴 **17.5개** — 태그가 많을수록 유리하나 효과 미미
- **감탄사(!)·질문(?)·숫자 포함 제목이 오히려 바이럴 비율 낮음** — 어그로성 제목보다 콘텐츠 품질이 핵심

국가별 인사이트

- **GB(영국)** 바이럴 비율 **44.1%** 로 4개국 중 1위 — 영어권 + 소규모 크리에이터 생태계 특성
- **US** 32.0%, **CANADA** 18.5%, **FRANCE** 6.2% 순
- **FRANCE**는 영어 콘텐츠 중심 플랫폼에서 현지 언어 콘텐츠의 글로벌 도달 한계가 반영된 결과

모델링 시 주의사항

- **likes / comment_count** 는 업로드 이후 집계되는 값 → 업로드 전에 측 서비스에 그대로 쓰면 데이터 리크
- 바이럴 레이블 25%:75% 불균형 → `class_weight='balanced'` 또는 `scale_pos_weight` 필수
- 동일 영상이 여러 국가에서 트렌딩되면 중복 행 존재 가능 → 영상 ID 기준 중복 제거 검토 필요